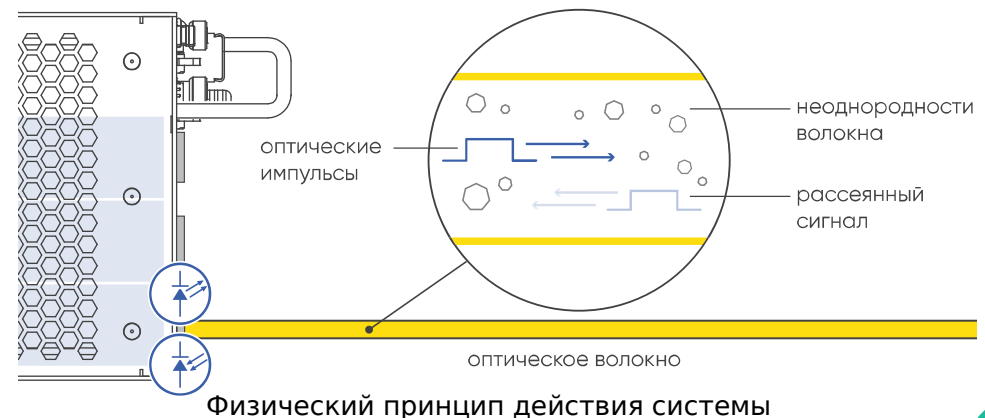


Модель сегментации сигналов целевых воздействий на данных с распределенного акустического сенсора

Черненко А.Е.

Распределенный акустический сенсор

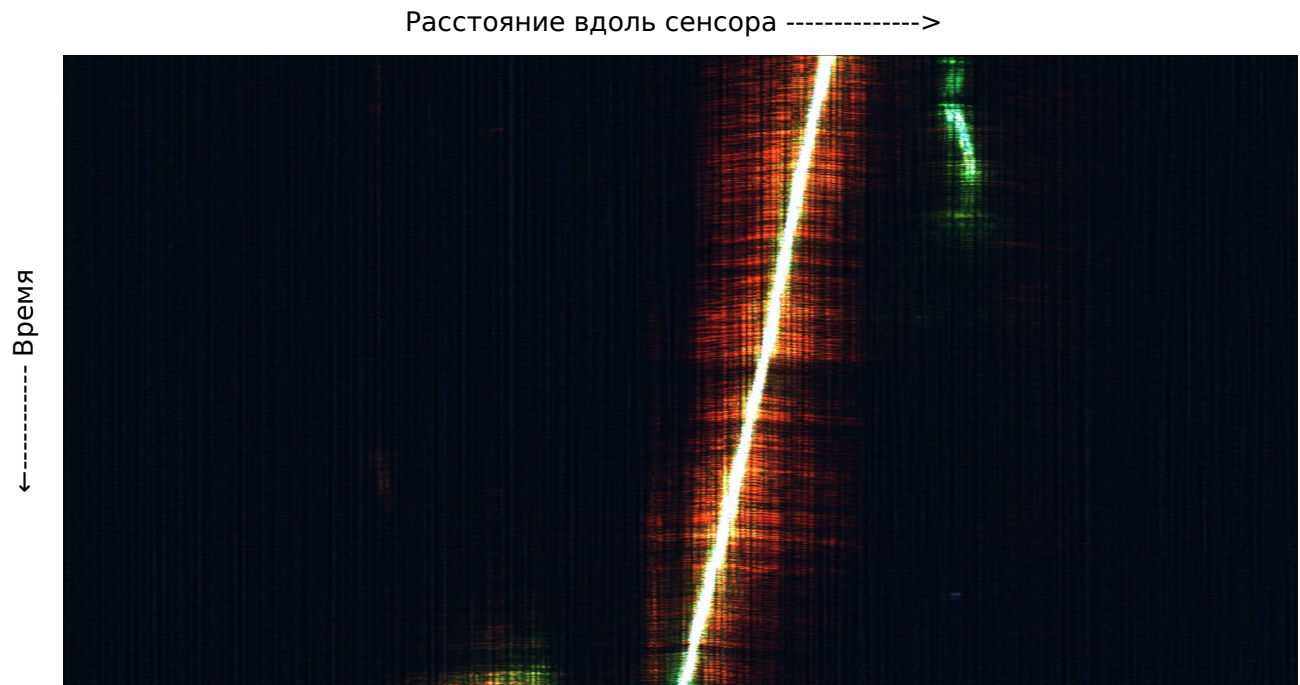
- Распределенный акустический сенсор (Distributed Acoustic Sensor, DAS) позволяет обнаруживать вибрацию грунта (акустические колебания) на расстоянии до нескольких десятков километров вдоль оптического кабеля.
- В основе работы системы лежит принцип когерентной рефлектометрии. В волокно периодически вводятся оптические импульсы, часть света рассеивается на неоднородностях волокна и распространяется в обратном направлении. При микродеформациях волокна, вызванных виброакустическими воздействиями, параметры рассеянного (отраженного) сигнала изменяются. Анализируя изменения в интерференционной картине сигнала обратного рассеяния, можно определить место и характер воздействия на волокно.
- Определение характера воздействия возможно за счет применения различных нейросетевых распознавателей.



Данные распределенного акустического сенсора

- Одним из возможных представлений данных с распределенного акустического сенсора является трехканальное изображение (“водопад”), горизонтальная ось связана с расстоянием вдоль сенсора, вертикальная – со временем.


Задачи локализации и определения характера воздействия по данному типу представления данных можно решать методами компьютерного зрения.



Фрагмент водопада с характерным следом сигнала от проезжающего автомобиля

Задача проекта

- **Задача проекта** – создание прототипа фреймворка по подготовке моделей сегментации целевых воздействий
- В данном проекте для примера подготовлена модель сегментации акустических следов сигнала от движения пешехода.



Примеры сэмплов и их масок разметки

Подготовка данных

- Имеется набор подготовленных и размеченных записей водопада. Данные и разметка сохранены в файлах формата HDF5. Записи разбиты на тренировочную, валидационную и тестовую выборки. Пути к записям по выборкам сохранены в файле **bundle/records.py**.
- Скрипт **bundle/lim_seg_bundle.py** подготавливает бандл **data/c_bundle_hs_128_256.h5** с информацией для нарезки сэмплов по заданным правилам (размеры сэмпла, шаг сдвига центра сэмпла).
- Структура бандла **data/c_bundle_hs_128_256.h5**:
 - **Атрибуты**: размеры сэмпла, прореживание сэмпла, список классов разметки, индексы которых соответствуют лейблу класса.
 - Датасет **records_map** – массив строк, содержащих пути к записям. Индекс элемента массива соответствует лейблу записи.
 - Группы **train**, **val**, **test**. Структура группы:
 - Датасет **coords** – массив координат центра сэмпла в записи.
 - Датасет **labels** – массив лейблов класса сигнала в сэмпле.
 - Датасет **records** – массив лейблов записи, с которой нарезается сэмпл.
 - Индексы элементов в датасетах соответствуют номеру сэмпла.

Датасет

- Класс датасета реализован в **utils/dataset.py** на базе `torch.utils.data.Dataset`.

```
class SegDataset(torch.utils.data.Dataset):  
  
    def __init__(self,  
        bundle_path: str,  
        group_name: str,  
        markup_mapping: Dict,  
        filter_id: int = 0):
```

Аргументы конструктора:

- bundle_path*** – путь к бандлу `data/c_bundle_hs_128_256.h5`;
- group_name*** – название выборки (`train`, `val`, `test`);
- markup_mapping*** – маппинг классов разметки в целевые классы предсказаний;
- filter_id*** – номер фильтра, в данном проекте к каждому сэмплу применяется преобразование $\log(x+1)$.

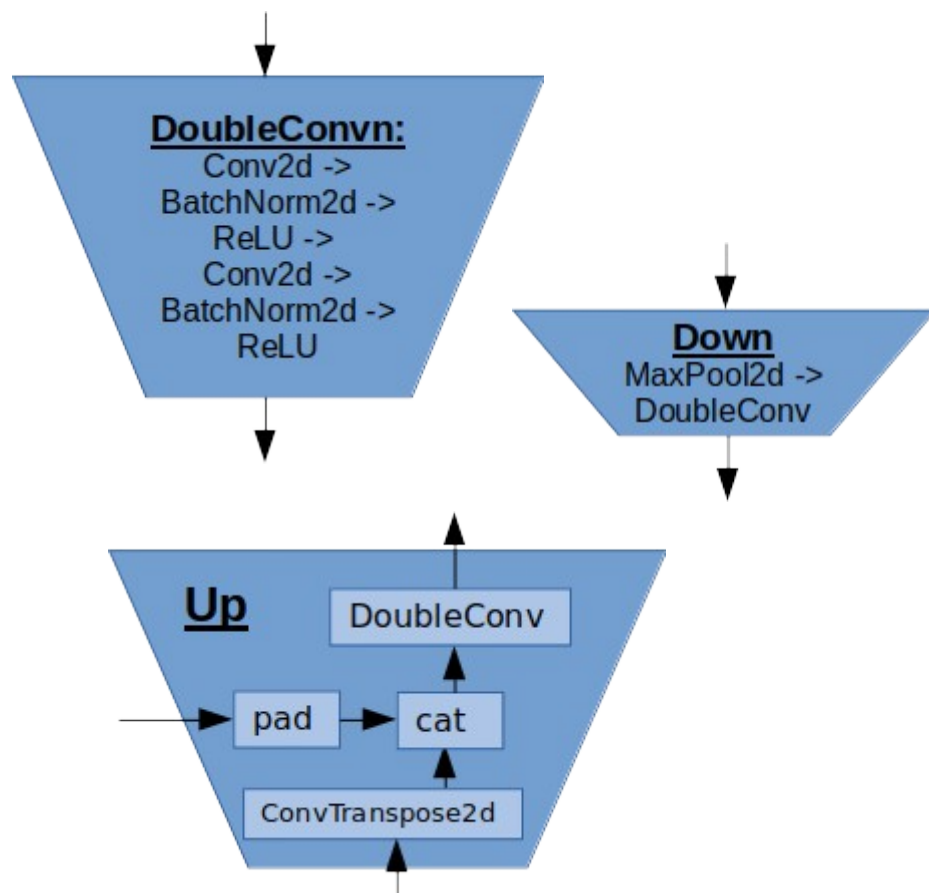
Также в конструкторе датасета рассчитываются веса сэмплов (свойство **weights**).

Метод **SegDataset.__getitem__(index)** считывает из выборки бандла информацию по нарезке сэмпла с номером `index`. Вырезает из записи по координатам и правилам сэмпл, выполняет перобразование фильтром. Также вырезает из записи разметки соответствующий сэмплу и лейблу класса фрагмент маски. Возвращает словарь с двумя элементами: `'image'` – `torch.Tensor` с данными сэмпла, `'mask'` `torch.Tensor` – с данными маски разметки.

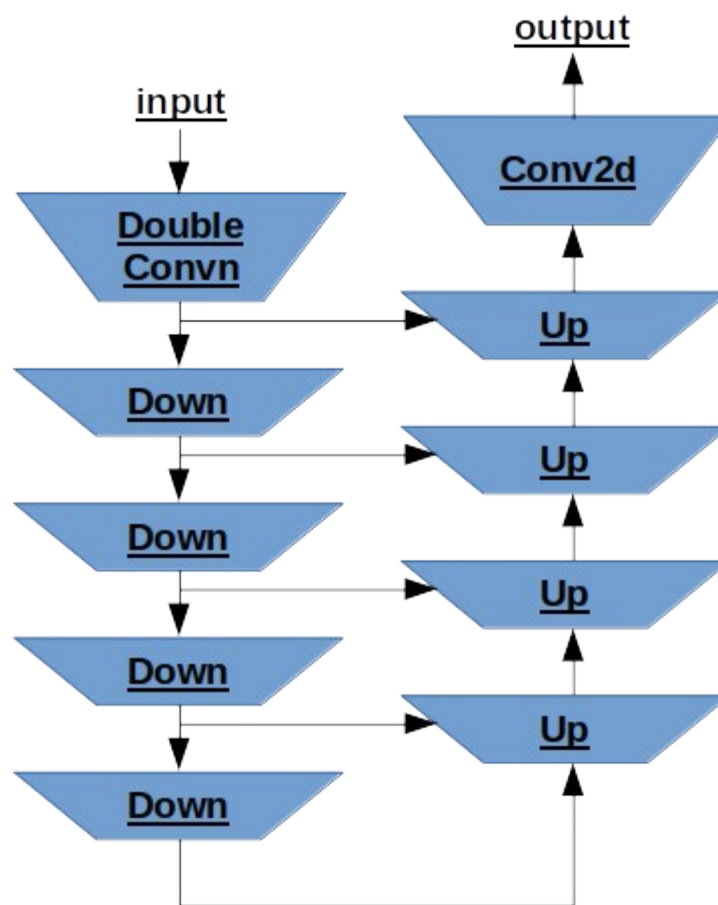
Архитектура модели

Архитектура модели - Unet. Модель взята из проекта <https://github.com/milesial/Pytorch-UNet>

- **unet/blocks.py** - блоки модели



- **unet/model.py** - каркас модели



Тренировка модели

- В `conf.py` задаются параметры для обучения
- Процедура обучения сети реализована в `train.py`
- Процедура оценки метрики (dice) реализована в `evaluate.py`, используется в конце каждой эпохи
- Данные в бандле избыточны: один и тот же участок сигнала может присутствовать в нескольких сэмплах, но локализован в разных участках сэмпла. Поэтому на этапе обучения `DataLoader` использует `WeightedRandomSampler`, который случайно (используя веса сэмплов) сэмплирует из датасета ограниченное число примеров на одну эпоху. Случайность в валидационном сэмплере заморожена, чтобы на всех эпохах использовалась одна и та же валидационная выборка
- `Optimizer` - `RMSprop`
- `Sheluder` - `ReduceLROnPlateau`
- `Loss` - `CrossEntropy` + `Dice`

Тренировка модели

Лог обучения:

INFO: Using device cuda
INFO: Network:
3 input channels
1 output channels (classes)

```
INFO: Starting training:
Epochs:      50
Batch size:   16
Learning rate: 0.0001
Training size: 1024
Validation size: 1024
Checkpoints:  True
Device:       cuda
Mixed Precision: True
```

```
INFO: Validation Dice score: 0.770007312297821
Epoch 1/50: 100%|██████████████████████████████████████| 1024/1024 [00:11<00:00, 86.27img/s, loss (batch)=0.246]
INFO: Checkpoint 1 saved!
INFO: Validation Dice score: 0.8117258548736572
Epoch 2/50: 100%|██████████████████████████████████████| 1024/1024 [00:11<00:00, 88.48img/s, loss (batch)=0.226]
INFO: Checkpoint 2 saved!
INFO: Validation Dice score: 0.806232213973999
Epoch 3/50: 100%|██████████████████████████████████████| 1024/1024 [00:11<00:00, 88.35img/s, loss (batch)=0.178]
INFO: Checkpoint 3 saved!
INFO: Validation Dice score: 0.7977456450462341
Epoch 4/50: 100%|██████████████████████████████████████| 1024/1024 [00:11<00:00, 88.31img/s, loss (batch)=0.191]
INFO: Checkpoint 4 saved!
INFO: Validation Dice score: 0.8244051933288574
Epoch 5/50: 100%|██████████████████████████████████████| 1024/1024 [00:11<00:00, 88.69img/s, loss (batch)=0.188]
INFO: Checkpoint 5 saved!
INFO: Validation Dice score: 0.7886080741882324
Epoch 6/50: 100%|██████████████████████████████████████| 1024/1024 [00:11<00:00, 88.90img/s, loss (batch)=0.198]
INFO: Checkpoint 6 saved!
INFO: Validation Dice score: 0.8325081467628479
Epoch 7/50: 100%|██████████████████████████████████████| 1024/1024 [00:11<00:00, 88.65img/s, loss (batch)=0.193]
INFO: Checkpoint 7 saved!
INFO: Validation Dice score: 0.8189709782600403
Epoch 8/50: 100%|██████████████████████████████████████| 1024/1024 [00:11<00:00, 89.28img/s, loss (batch)=0.223]
INFO: Checkpoint 8 saved!
INFO: Validation Dice score: 0.8358147740364075
Epoch 9/50: 100%|██████████████████████████████████████| 1024/1024 [00:11<00:00, 89.12img/s, loss (batch)=0.162]
INFO: Checkpoint 9 saved!
INFO: Validation Dice score: 0.8286530375480652
Epoch 10/50: 100%|██████████████████████████████████████| 1024/1024 [00:11<00:00, 88.89img/s, loss (batch)=0.211]
INFO: Checkpoint 10 saved!
```

Тестирование модели


В **testing.py** реализован класс **TestModel**, инструмент для тестирования модели. Для инициализации требуется указать путь к модели и экземпляр датасета.

Метод **predict_by_idx(idx, threshold=None)** возвращает массив с данными сэмпла, массив с маской разметки сэмпла, массив с данными сегментации. Номер сэмпла в датасете задается `idx`. При указании порог `threshold` будет применен к данным сегментации, по умолчанию данные сегментации отражают тепловую карту вероятностей предсказаний.

Метод **show_predict_by_idx(idx, threshold=None)** показывает изображения сэмпла, маски разметки и сегментации.

Метод **evaluate(n_samples, batch_size=8, random_state=0)** возвращает среднюю по случайной выборке из `n_samples` сэмплов оценку метрики `dice`.

Тестирование модели



Средняя оценка метрики dice на тестовой выборке из 1024 сэмплов: **0.8248**

Что следует улучшить

- Реализовать многоклассовую сегментацию
- Разработать метрики, которые лучше соответствуют бизнес-задаче.
- Реализовать процедуру оптимизации гиперпараметров при обучении моделей
- Реализовать технику распределенного обучения на нескольких гпу и серверах